

MQ101 Lista05 WolffAnaCarolina

2026-01-31

MQ101 — Métodos Quantitativos para Políticas Públicas

Lista de Exercícios #05

Nome: Ana Carolina Wolff

RA: 23202510326

Turma: PPU-009 - MÉTODOS QUANTITATIVOS -
TPPU00920253 (2025.3 - 4T234)

Data: 17/12/2025

Descrição: Teste de Hipóteses e Regressão

```
knitr::opts_chunk$set( echo = TRUE, message = FALSE, warning = FALSE, dpi = 96 ) library(tidyverse) library(broom) set.seed(123)
```

```
#Geração da base de dados fictícia n <- 400
```

```
dados <- tibble( id = 1:n, idade = round(rnorm(n, mean = 40, sd = 12)), sexo = sample(c("F", "M"), n, replace = TRUE, prob = c(0.55, 0.45)), renda = round(rlnorm(n, meanlog = log(2500), sdlog = 0.5), 0), escolarid = sample(c("fundamental", "medio", "superior"), n, replace = TRUE, prob = c(0.30, 0.40, 0.30)), ideologia = round(runif(n, 0, 10), 0), # 0 = esquerda, 10 = direita apoio_gov = rbinom(n, 1, plogis(-1 + 0.015(idade - 40) + 0.4(sexo == "F") + 0.5(renda > 3000))), satisf_gov = pmin(pmax( round(3 + 2apoio_gov + 0.001(renda - 2500) + rnorm(n, 0, 2), 0), 10), protesto = rbinom(n, 1, plogis(-2 + 0.3(ideologia <= 4) - 0.2*apoio_gov)) ) ) glimpse(dados)
```

```
#Exercício 01 - Exploração descritiva e gráficos básicos
```

```
#1.1 #média, mediana, desvio-padrão e quartis de idade, renda e satisf_gov:
```

```
summary(dados$idade) summary(dados$renda) summary(dados$satisf_gov)
```

Média

```
mean(dados$idade, na.rm = TRUE) mean(dados$renda, na.rm = TRUE) mean(dados$satisf_gov, na.rm = TRUE)
```

Mediana

```
median(dados$idade, na.rm = TRUE) median(dados$renda, na.rm = TRUE) median(dados$satisf_gov, na.rm = TRUE)
```

Desvio-padrão

```
sd(dados$idade, na.rm = TRUE) sd(dados$renda, na.rm = TRUE) sd(dados$satisf_gov, na.rm = TRUE)
```

Quartis

```
quantile(dados$idade, probs = c(0.25, 0.5, 0.75), na.rm = TRUE) quantile(dados$renda, probs = c(0.25, 0.5, 0.75), na.rm = TRUE)
quantile(dados$satisf_gov, probs = c(0.25, 0.5, 0.75), na.rm = TRUE)
```

```
#proporção de respondentes por categoria de sexo e escolaridade
```

```
prop.table(table(dados$sexo)) prop.table(table(dados$escolarid))
```

Proporção de respondentes com apoio_gov = 1

```
mean(dados$apoio_gov == 1, na.rm = TRUE)
```

```
#1.2. Construa os seguintes gráficos: #um histograma de renda (use pelo menos 20 quebras)
```

```
ggplot(dados, aes(x = renda)) + geom_histogram(bins = 20)
```

```
#um histograma ou gráfico de barras da distribuição de satisf_gov;
```

```
ggplot(dados, aes(x = satisf_gov)) + geom_histogram(bins = 20)
```

#um gráfico de barras com a distribuição de escolaridade

```
ggplot(dados, aes(x = escolarid)) + geom_bar()
```

#1.3 Comente #se a distribuição de renda parece simétrica ou assimétrica: no gráfico, a distribuição de renda aparece assimétrica, com concentração à esquerda e uma longa cauda que se estende para os valores mais altos. #se satisf_gov parece concentrada em valores baixos, médios ou altos: a variável satisf_gov parece concentrada em valores médios, entre os valores 4 e 5. #como se distribuem sexo e escolarid na amostra: há uma predominância feminina e de nível médio.

```
ggplot(dados, aes(x = escolarid, fill = sexo)) + geom_bar(position = "dodge")
```

#EXERCÍCIO 2 - Escolha de testes estatísticos

#2.1. Identifique o tipo de cada variável: categórica ou contínua. #2.2. Indique qual teste bivariado é mais adequado, considerando o Capítulo 8 (análise tabular e qui-quadrado, diferença de médias, correlação, regressão simples).

#a. #tipo de sexo: qualitativa nominal #tipo de apoio_gov: qualitativa nominal #teste bivariado sugerido: análise tabular/qui-quadrado

#b. #escolarid (3 categorias): qualitativa ordinal #apoio_gov (0/1): qualitativa nominal #teste bivariado sugerido: análise tabular/qui-quadrado

#c. #satisf_gov (0–10): quantitativa discreta #apoio_gov (0/1): qualitativa nominal #teste bivariado sugerido: Teste t de diferença de médias

#d. #satisf_gov (0–10): quantitativa discreta #renda (contínua): quantitativa contínua. #teste bivariado sugerido: correlação e/ou regressão simples

#e. #satisf_gov (0–10): quantitativa discreta #ideologia (0–10): quantitativa discreta #teste bivariado sugerido: correlação e/ou regressão simples

#Exercício 3 – Teste qui-quadrado: sexo e apoio ao governo

#3.1. Construa uma tabela de contingência entre sexo e apoio_gov. Apresente também proporções por coluna (ou por linha) para facilitar a interpretação.

```
tab_sexo_apoio <- table(dados$sexo, dados$apoio_gov) tab_sexo_apoio prop.table(tab_sexo_apoio, margin = 2)
```

#3.2 Formule as hipóteses: H_0 : não há associação entre sexo e apoio_gov na população; H_1 : há associação entre sexo e apoio_gov.

#3.3. Aplique o teste de qui-quadrado em R: `chisq.test(tab_sexo_apoio)`

#3.4 Em texto, interprete: #O resultado do teste indicou um valor de qui-quadrado de aproximadamente 0,68, com 1 grau de liberdade e um valor-p de 0,4063. #Como o valor-p é muito superior ao nível de significância usual de 5%, não rejeitamos a hipótese nula. #Isso significa que, com base nesta amostra, não há evidências estatísticas de que o sexo influencie o apoio ao governo.

#3.5 CONstrua gráfico

```
ggplot(dados, aes(x = sexo, fill = factor(apoio_gov))) + geom_bar(position = "fill") + scale_y_continuous(labels = scales::percent) + labs(fill = "Apoio ao governo")
```

#Comente: sim, há coerência entre o gráfico e o resultado do teste. #embora visualmente os homens pareçam apresentar um apoio ligeiramente maior, a diferença é pequena e não significativa do ponto de vista estatístico.

#Exercício 4 – Diferença de médias: renda entre apoiadores e não apoiadores

#4.1. Produza um resumo numérico de renda por apoio_gov (média, desvio-padrão, tamanho de cada grupo).

```
dados %>% group_by(apoio_gov) %>% summarise( media_renda = mean(renda), sd_renda = sd(renda), n = n() )
```

#4.2. Formule as hipóteses: $H_0: \mu_{\text{apoia}} = \mu_{\text{não apoia}}$ $H_1: \mu_{\text{apoia}} \neq \mu_{\text{não apoia}}$

#4.3. Aplique o teste t para diferença de médias (assuma, inicialmente, variâncias desiguais):

```
t.test(renda ~ apoio_gov, data = dados)
```

#4.4. Em texto, interprete:

#Estimativa da diferença de médias: a média da renda entre os que não apoiam o governo foi de 2.772,36 reais, enquanto entre os que apoiam foi de 3.025,48 reais. A diferença estimada entre as médias é de aproximadamente 253,12 reais (3025,48 – 2772,36). #Intervalo de confiança de 95%: o intervalo de confiança para a diferença de médias foi de [-576,66 ; 70,41]. Como esse intervalo inclui o valor 0, não podemos afirmar que exista diferença estatisticamente significativa entre os grupos. #O valor-p obtido foi 0,1247. Esse valor é maior que 0,05, indicando que a diferença observada pode ser explicada pelo acaso. #Conclusão sobre H_0 a 5%: como o valor-p é maior que o nível de significância de 5%, não rejeitamos a hipótese nula. #Portanto, não há evidências estatísticas de que a renda difira entre apoiadores e não apoiadores do governo nesta amostra. #embora os apoiadores tenham uma média de renda ligeiramente maior, essa diferença não é estatisticamente significativa.

#4.5. Construa um boxplot de renda por apoio_gov e comente brevemente a relação entre o gráfico e o resultado do teste.

```
ggplot(dados, aes(x = factor(apoio_gov), y = renda)) + geom_boxplot()
```

#Comentário: #No gráfico, observa-se que as medianas são próximas e as caixas e limites externos se sobrepõem bastante, sugerindo distribuições semelhantes entre os grupos. Isso sugere que a distribuição das rendas nos dois grupos é semelhante e que a diferença visual não é muito marcada. #No teste t, essa impressão visual se confirma: a diferença média foi de cerca de R\$ 253, mas o intervalo de confiança inclui o zero ([-576 ; 70]) e o valor-p (0,1247) é maior que 0,05. Isso significa que a diferença observada não é estatisticamente significativa. #o gráfico mostra uma diferença pequena e com grande sobreposição entre os grupos, e o teste t confirma que essa diferença não é significativa do ponto de vista estatístico.

#Exercício 5 – Correlação: renda, ideologia e satisfação com o governo

#5.1. Calcule a matriz de correlações de Pearson entre renda, ideologia e satisf_gov completos):

```
dados %>% select(renda, ideologia, satisf_gov) %>% cor(use = "complete.obs")
```

#5.2 Para cada par de variáveis, com base na matriz:

#Renda e ideologia: correlação +0,0205 (positiva); associação muito fraca; não há associação relevante entre renda e ideologia na amostra

#Renda e satisf_gov: correlação +0,5934 (positiva); associação moderada a forte; assim, quanto maior a renda, maior tende a ser a satisfação com o governo, em termos gerais. #Ideologia e satisf_gov: correlação -0,0796 (negativa); associação muito fraca; sugere que a ideologia tem pouca relação com a satisfação com o governo.

#5.3 Construa um gráfico de dispersão de renda (eixo x) por satisf_gov (eixo y), com linha de tendência linear:

```
ggplot(dados, aes(x = renda, y = satisf_gov)) + geom_point(alpha = 0.4) + geom_smooth(method = "lm", se = TRUE)
```

#5.4. Em texto, comente o padrão visual do gráfico, relacionando-o ao sinal e magnitude da correlação estimada.

#O gráfico de dispersão com linha de regressão mostra uma tendência clara de associação positiva entre renda e satisfação com o governo: conforme a renda aumenta, a satisfação tende também a crescer. #Esse padrão visual está em plena concordância com o coeficiente de correlação estimado (+0,59), que indica uma relação moderada a forte. #A inclinação positiva da linha e a proximidade relativa dos pontos reforçam a ideia de que indivíduos com maior renda apresentam, em média, níveis mais altos de satisfação, ainda que exista alguma dispersão nos dados.

#Exercício 6 – Regressão linear simples: satisfação e renda

#Considere o modelo: $\hat{y}_i = \beta_0 + \beta_1 x_i + \epsilon_i$

#6.1. Estime o modelo em R:

```
mod1 <- lm(satisf_gov ~ renda, data = dados) summary(mod1)
```

#6.2. Em texto, interprete:

#O modelo de regressão linear simples indica que, quando a renda é igual a zero, a satisfação esperada com o governo seria de aproximadamente 1,35 pontos, embora essa interpretação literal do intercepto não seja muito significativa na prática. #Já o coeficiente da renda mostra um efeito positivo: para cada aumento de 1.000 reais na renda, espera-se um acréscimo médio de cerca de 1 ponto na satisfação com o governo. #O valor-p associado à renda é extremamente baixo (menor que 0,001), fornecendo forte evidência estatística de associação linear entre renda e satisfação. #assim, conclui-se que a renda é um preditor significativo e que indivíduos com maior renda tendem, em média, a apresentar maior satisfação com o governo.

#6.3. Utilize o broom para obter uma tabela organizada:

```
tidy(mod1)
```

#O output do modelo mostra que o intercepto estimado é 1,35, com erro-padrão de 0,227, resultando em uma estatística t de 5,94 e valor-p de 6,3e-9, o que indica que ele é estatisticamente diferente de zero, embora sua interpretação literal (satisfação quando a renda é zero) não seja muito relevante. #já o coeficiente da renda é 0,00102, com erro-padrão extremamente baixo (0,0000692), o que gera uma estatística t muito elevada (14,7) e um valor-p praticamente nulo (2,08e-39). #Esses resultados evidenciam que a renda tem efeito positivo e altamente significativo sobre a satisfação com o governo, confirmando a robustez da associação linear encontrada.

#6.4. Refaça o gráfico de dispersão com reta de regressão (como no Exercício 5) e escreva um parágrafo relacionando:

```
ggplot(dados, aes(x = renda, y = satisf_gov)) + geom_point(alpha = 0.4) + geom_smooth(method = "lm", se = TRUE)
```

#O gráfico de dispersão com a reta de regressão mostra uma tendência positiva clara entre renda e satisfação com o governo, em linha com o coeficiente estimado $\beta_1 = 0,00102$. #A inclinação positiva da reta reflete o sinal do coeficiente, indicando que maiores valores de renda estão associados a maiores níveis de satisfação. #Além disso, o valor elevado da estatística t (14,7) e o valor-p praticamente nulo ($< 0,001$) confirmam a significância estatística desse efeito, evidenciando que a associação linear observada no gráfico não é fruto do acaso, mas sim uma relação consistente entre as variáveis

#Exercício 7 – Diagnóstico simples do modelo

#Usando o modelo do Exercício 6 (mod1):

```
mod1 <- lm(satisf_gov ~ renda, data = dados) summary(mod1)
```

#7.1. Extraia resíduos e valores ajustados: `dados_diag <- augment(mod1)` `glimpse(dados_diag)`

#7.2. Construa:

#um gráfico de resíduos vs valores ajustados (.resid vs .fitted);

```
ggplot(dados_diag, aes(x = .fitted, y = .resid)) + geom_point(alpha = 0.4) + geom_hline(yintercept = 0, linetype = "dashed")
```

#um gráfico QQ-plot dos resíduos.

```
ggplot(dados_diag, aes(sample = .resid)) + stat_qq() + stat_qq_line()
```

#7.3. Em texto, com base nos gráficos, comente: #se há indícios fortes de heterocedasticidade (padrão em funil, por exemplo); #se a distribuição dos resíduos parece muito distante de algo aproximadamente normal.

#no gráfico de resíduos versus valores ajustados, não se observa um padrão em funil ou outro indício forte de heterocedasticidade: a dispersão dos resíduos parece relativamente constante ao longo da reta, sugerindo que a variância dos erros é aproximadamente homogênea. #o gráfico Q-Q mostra que os resíduos seguem de forma razoável a linha de referência, com pequenas desvios nas extremidades. Isso indica que a distribuição dos resíduos não está muito distante da normalidade, havendo apenas leves discrepâncias nas caudas. #os diagnósticos sugerem que as principais suposições do modelo linear — homocedasticidade e normalidade dos resíduos — estão suficientemente atendidas para que os resultados sejam considerados confiáveis.

#7.4. Explique, em poucas linhas, por que vale a pena olhar pelo menos esses dois gráficos antes de confiar inteiramente nas inferências do modelo.

#Vale a pena olhar esses dois gráficos, porque eles ajudam a verificar se as condições básicas do modelo estão sendo atendidas. #O gráfico de resíduos mostra se os erros estão distribuídos de forma equilibrada, sem padrões que indiquem problemas como variação desigual. #Já o gráfico de normalidade indica se os erros seguem aproximadamente a distribuição esperada. #Se esses pontos não forem avaliados, corre-se o risco de confiar em resultados que podem estar distorcidos pelas limitações do modelo.

#Exercício 8 – Regressão com variável dummy e diferença de médias

#Considere o modelo: $\hat{y}_i = \beta_0 + \beta_1 x_i + \epsilon_i$ #onde `apoio_gov` é uma variável indicadora (0 = não apoia; 1 = apoia).

#8.1. Estime o modelo:

```
mod2 <- lm(satisf_gov ~ apoio_gov, data = dados)
```

```
summary(mod2)
```

#8.2. Calcule as médias de `satisf_gov` nos dois grupos (`apoio_gov = 0` e `apoio_gov = 1`) e compare com os coeficientes de `mod2`. #No modelo com variável dummy, o intercepto representa a média de satisfação dos que não apoiam o governo (3,41). #O coeficiente da dummy mostra a diferença entre os grupos (2,27), e somando os dois obtemos a média dos apoiadores (5,68). #Ou seja, os coeficientes da regressão reproduzem exatamente as médias observadas nos dois grupos.

#8.3. Mostre, com base nos resultados numéricos, que: # $\hat{\beta}_0$ corresponde à média de `satisf_gov` para `apoio_gov = 0`; # $\hat{\beta}_1$ corresponde à diferença entre as médias dos dois grupos.

#O intercepto ($\beta_0=3,412$) corresponde exatamente à média de satisfação com o governo para o grupo que não apoia (`apoio_gov = 0`). #O coeficiente da dummy ($\beta_1=2,268$) representa a diferença entre as médias dos dois grupos. #Assim, a média dos que apoiam o governo é dada por: $\beta_0 + \beta_1 = 3,412 + 2,268 = 5,680$ #Comparando: #Média dos que não apoiam = 3,41 #Média dos que apoiam = 5,68 #Diferença = 2,27 → que coincide com β_1 .

#8.4. Aplique:

```
t.test(satisf_gov ~ apoio_gov, data = dados)
```

#Compare o valor-p de `apoio_gov` no `summary(mod2)` com o valor-p do `t.test`. Em texto, discuta a relação entre os dois resultados.

#O valor-p do coeficiente de `apoio_gov` na regressão é praticamente zero ($< 2e-16$), assim como o valor-p do teste t ($< 2,2e-16$). #Isso acontece porque os dois testes são, na prática, equivalentes: ambos verificam se há diferença significativa entre as médias de satisfação dos que apoiam e dos que não apoiam o governo. #assim, os dois resultados confirmam a mesma conclusão: a diferença entre os grupos é estatisticamente muito significativa.