

=====

MQ101 — Métodos Quantitativos para Políticas Públicas

Lista de Exercícios #02

Nome: Ana Carolina Wolff

RA: 23202510326

Turma: PPU-009 - MÉTODOS QUANTITATIVOS - TPPU00920253
(2025.3 - 4T234)

Data: 09/10/2025

Descrição: Tipos de Variáveis e Estatísticas Descritivas

#EXERCÍCIO 1 - Preparação de ambiente

```
install.packages(c("tidyverse", "readr")) library(tidyverse) options(scipen = 999)
```

```
install.packages("ggplot2") library(ggplot2)
```

#EXERCÍCIO 2 - Base de dados (contexto e dicionário) #Verifique: número de linhas/colunas; classes das variáveis; existência de NA.

```
dados <- readr::read_csv("data/educ_saude.csv") #atribuir
```

```
dados <- read.csv (file.choose()) #outra forma de chamar os dados
```

```
install.packages("dplyr") # ou install.packages("tibble")
```

```
library(dplyr) # ou library(tibble)
```

```
glimpse(dados) summary(dados)
```

```
nrow(dados) ncol(dados) str (dados)
```

```
sum(is.na(dados)) colSums(is.na(dados))
```

#RESPOSTA: # Linhas = 10.000 e Colunas = 13 #classe das variáveis: quantitativas e qualitativas # não há NA

#EXERCÍCIO 3 - Classificação de variáveis #Faça uma tabela (no seu script) indicando o tipo teórico de cada variável (nominal, ordinal, discreta, contínua).

```
dados <- dados |> mutate( sexo = factor(sexo), rede_escolar = factor(rede_escolar), plano_saude  
= factor(plano_saude), diagnostico = factor(diagnostico), escolaridade = factor(escolaridade, levels =  
c("Fundamental", "Médio", "Superior"), ordered = TRUE) )
```

```

str(dados) glimpse(dados)

dfl <- data.frame (variavel = c ("sexo","escolaridade","anos_estudo", "rede_escolar","municipio","UF","idade",
"faltas_esc","tempo_estudo_h", "pressao_sistolica","diagnostico", "plano_saude"),

tipoteorico = c ("qualitativa nominal","qualitativa ordinal", "quantitativa discreta", "qualitativa nominal",
"qualitativa nominal", "qualitativa nominal", "quantitativa contínua", "quantitativa discreta", "quantitativa
contínua", "quantitativa contínua", "qualitativa nominal", "qualitativa nominal"),

stringAsFactors=FALSE)

dfl

#Registre, em comentários, por que cada variável é daquele tipo.

#sexo (F/M) — qualitativa nominal -> categorias sem ordem natural #escolaridade (Fundamen-
tal/Médio/Superior) — qualitativa ordinal -> categorias com hierarquia que indica progressão/nível de
instrução #anos de estudo - quantitativa discreta - contagem inteira #rede_escolar (pública/privada)
— qualitativa nominal -> não há hierarquia entre pública e privada #município - qualitativa nominal -
categorias sem ordem natural entre elas #UF - qualitativa nominal - categorias sem ordem natural entre
elas #idade (anos) — quantitativa contínua -> pode assumir qualquer valor real, mesmo que na prática
seja registrada em inteiros #faltas_esc (nº faltas no último mês) — quantitativa discreta -> contagem de
eventos, não admite frações #tempo_estudo_h (horas por semana) — quantitativa contínua -> pode ser
fracionado #pressao_sistolica (mmHg) — quantitativa contínua -> medida em escala contínua #diagnostico
("sem", "HAS", "DM", "outros") — qualitativa nominal -> categorias sem ordem natural #plano_saude
(SUS/privado/ambos/nenhum) — qualitativa nominal -> não há hierarquia natural entre as opções

#EXERCÍCIO 4 - variáveis qualitativas - frequências e gráficos

tab_plano <- table(dados$plano_saude) tab_plano

prop_plano <- prop.table(tab_plano) prop_plano

cbind(FA = tab_plano, FR = round(100 * prop_plano, 1))

#Tarefa 4A - Frequências absolutas e relativas #Interprete: qual categoria é a moda? Categoria SUS
(0,5024). #Qual a proporção dominante? 50%.

#Tarefa 4B - Gráfico de barras (qualitativa nominal)

dados |> count(plano_saude) |> ggplot(aes(x = plano_saude, y = n)) + geom_col() + labs(x = "Plano de
saude", y = "Frequência", title = "Distribuição de plano de saúde")

#Tarefa 4C - Barras ordenadas (qualitativa ordinal)

dados |> count(escolaridade) |> ggplot(aes(x = escolaridade, y = n)) + geom_col() + labs(x = "Escolaridade
(ordem substantiva)", y = "Frequência")

#Explique por que a ordem importa para interpretar a distribuição? #No gráfico de barras de uma variável
qualitativa ordinal, como escolaridade, a ordem das categorias é fundamental porque reflete uma hierarquia
natural (Fundamental < Médio < Superior). #Se as barras forem apresentadas fora dessa sequência, perde-
se a noção de trajetória educacional e a interpretação pode ficar confusa. #Manter a ordem correta permite
identificar tendências, como a concentração em níveis mais baixos ou o avanço para níveis mais altos, além
de facilitar comparações com outras variáveis relacionadas.

#EXERCÍCIO 5 - Variáveis quantitativas — medidas e distribuição #Escolha duas variáveis: idade e pres-
sao_sistolica. #Tarefa 4A. Tendência central e dispersão

sumario_idade <- dados |> summarise( n = sum(!is.na(idade)), media = mean(idade, na.rm = TRUE),
mediana= median(idade, na.rm = TRUE), min = min(idade, na.rm = TRUE), max = max(idade, na.rm =
TRUE), dp = sd(idade, na.rm = TRUE) ) sumario_idade

```

n media mediana min max dp

```
# # 10000 40.4 40 18 80 12.5 #Média = 40.4 #mediana = 40
```

```
#Repita para pressao_sistolica.
```

```
sumario_pressao_sistolica <- dados |> summarise( n = sum(!is.na(pressao_sistolica)), media =  
mean(pressao_sistolica, na.rm = TRUE), mediana= median(pressao_sistolica, na.rm = TRUE), min  
= min(pressao_sistolica, na.rm = TRUE), max = max(pressao_sistolica, na.rm = TRUE), dp =  
sd(pressao_sistolica, na.rm = TRUE) ) sumario_pressao_sistolica
```

```
#Resultado: #n media mediana min max dp # # 10000 122. 122 85 175 14.1 #Média = 122 #Mediana =  
122
```

```
#RESPOSTA: A média é 122 e a mediana é 122.
```

```
#Compare média vs. mediana. Há assimetria?
```

#tanto no caso da idade como da pressão sistólica, a media e a mediana são praticamente iguais. #isso é um forte indicador de que a distribuição das variáveis nos dados é simétrica. #os valores estão bem distribuídos em torno do centro, sem uma “cauda” significativa de valores extremos (muito altos ou muito baixos) puxando a média para longe da mediana.

```
#Tarefa 4B. Histograma e boxplot
```

```
ggplot(dados, aes(x = idade)) + geom_histogram(bins = 20) + labs(title = “Histograma de Idade”)
```

```
ggplot(dados, aes(y = idade)) + geom_boxplot() + labs(title = “Boxplot de Idade”)
```

#Interprete forma, caudas e outliers. #RESPOSTA: No histograma de idade, observa-se um pico em torno dos 40 anos, indicando que a maior parte da amostra está concentrada nessa faixa etária. A frequência diminui gradualmente para os lados, com menos indivíduos nas idades mais jovens (abaixo de 20) e mais velhas (acima de 70), mostrando uma distribuição centralizada com caudas mais longas nas extremidades e alguns valores muito altos (outliers). #no boxplot a mediana aparece próxima dos 40 anos, bem centralizada na caixa, sugerindo simetria, enquanto os pontos acima do limite superior representam idades significativamente maiores que o restante da amostra (outliers). #o histograma detalha a forma da distribuição e a densidade em cada faixa, enquanto o boxplot resume em medidas de posição, dispersão e outliers.

```
#Repita para pressao_sistolica.
```

```
ggplot(dados, aes(x = pressao_sistolica)) + geom_histogram(bins = 20) + labs(title = “Pressão Sistólica”)
```

```
ggplot(dados, aes(y = pressao_sistolica)) + geom_boxplot() + labs(title = “Boxplot de Pressão Sistólica”)
```

```
#Interprete forma, caudas e outliers.
```

#histograma: a distribuição é centrada em torno de 120–130 mmHg, com caudas mais finas nas extremidades e poucos valores extremos, sugerindo que a pressão sistólica da amostra segue um padrão bastante regular.

#boxplot: evidencia que a distribuição é relativamente simétrica, com a maior parte dos indivíduos em torno da mediana, mas também revela a presença de alguns casos de pressão elevada (outliers) #o histograma detalha a forma e frequência dos dados, enquanto o boxplot resume em posição, dispersão e outliers.

```
#EXERCÍCIO 6 - Tabelas cruzadas e resumos por grupo #Tarefa 6A. Cruzando duas qualitativas
```

```
tab_cross <- table(dadosdiagnostico, dadosplano_saude) tab_cross round(100 * prop.table(tab_cross, mar-  
gin = 2), 1)
```

```
#Qual diagnóstico é mais prevalente dentro de cada tipo de plano?
```

#para o caso de “ambos os planos”: a maioria está na categoria “sem diagnóstico” (81,4%); #para “nenhum plano”, também predomina “sem diagnóstico” (80,7%); #no “plano privado”, novamente, o mais prevalente é “sem diagnóstico” (80,6%); #no “SUS” segue o mesmo padrão, com “sem diagnóstico” (80,7%). #entre os diagnósticos presentes, o que aparece com maior frequência relativa em todos os tipos de plano é HAS (hipertensão arterial sistêmica), em torno de 12% em cada grupo.

#Tarefa 6B. Resumo de quantitativa por grupo

```
dados |> group_by(sexo) |> summarise( n = n(), media_idade = mean(idade, na.rm = TRUE), dp_idade = sd(idade, na.rm = TRUE), mediana_idade = median(idade, na.rm = TRUE) )
```

```
dados |> group_by(escolaridade) |> summarise( n = n(), media_idade = mean(idade, na.rm = TRUE), dp_idade = sd(idade, na.rm = TRUE), mediana_idade = median(idade, na.rm = TRUE))
```

#Compare idade por sexo e por escolaridade. Comente diferenças.

#por sexo: mulheres (40,3 anos em média) e homens (40,5 anos) apresentam praticamente a mesma idade média, mediana (40 anos) e desvio padrão (~12,5). Isso indica que a distribuição etária é bastante equilibrada entre os sexos. #por escolaridade: os três níveis (Fundamental, Médio e Superior) também mostram médias muito próximas (entre 40,2 e 40,5 anos), mesma mediana (40 anos) e desvios padrão semelhantes (~12,5). #conclusão: tanto por sexo quanto por escolaridade, a idade dos indivíduos é bastante homogênea, sem diferenças significativas. Isso sugere que a variável idade não está associada de forma marcante a essas categorias no conjunto analisado.

#EXERCÍCIO 7 - Valores ausentes e outliers #Tarefa 7A. Ausentes

```
colSums(is.na(dados))
```

#Mostre resultados com e sem NA. Explique na.rm=TRUE.

#na.rm=TRUE:significa “remover os NA” antes de calcular; se não for usado, o resultado será NA sempre que houver valores faltantes; usar na.rm = TRUE garante que os cálculos sejam feitos apenas com os dados válidos, ignorando os valores faltantes.

#Tarefa 6B. Outliers (regra do IQR)

```
Q <- quantile(dados$tempo_estudo_h, probs = c(.25, .75), na.rm = TRUE) IQRv <- IQR(dados$tempo_estudo_h, na.rm = TRUE) lim_inf <- Q[1] - 1.5 * IQRv lim_sup <- Q[2] + 1.5 * IQRv
```

```
subset_out <- dados |> filter(tempo_estudo_h < lim_inf | tempo_estudo_h > lim_sup)
```

```
nrow(subset_out) #348 head(subset_out) #as primeiras seis linhas
```

#Discuta: outliers são erros, casos raros ou informação válida? #em alguns casos, valores extremos surgem por falhas e, por isso, devem ser removidos; #em outros casos, podem refletir situações pouco comuns, mas possíveis (ex. pessoa com idade muito avançada ou pressão arterial excepcionalmente alta). #ainda, outliers podem ser os dados mais interessantes, pois revelam diversidade ou situações que merecem atenção especial do analista de políticas públicas.

#EXERCÍCIO 8 - Exercícios aplicados (educação e saúde)

#EDUCAÇÃO

#8A Distribuição de rede_escolar (FA/FR).

#FA

```
table(dados$rede_escolar)
```

```
#privada = 2796 #pública = 7204
```

```
#FR prop.table(table(dados$rede_escolar)) * 100
```

```
#privada = 27,96% #pública = 72,04%
```

```
tab <- table(dados$rede_escolar) cbind(Frequencia_Absoluta = tab, Frequencia_Relativa = round(prop.table(tab)*100, 1))
```

#Interpretação: a frequência absoluta mostra quantos indivíduos estão em cada tipo de rede escolar, enquanto a relativa mostra a proporção em relação ao total

#8B Compare tempo_estudo_h por escolaridade com boxplots.

```
library(ggplot2)

ggplot(dados, aes(x = escolaridade, y = tempo_estudo_h)) + geom_boxplot(fill = "lightblue") + labs( x
= "Escolaridade", y = "Tempo de estudo (horas)", title = "Boxplots de tempo de estudo por escolaridade"
)

#8C Interprete: há padrão monotônico com a ordem da escolaridade?

#Sim, há um padrão monotônico claro na relação entre escolaridade e tempo de estudo. #Fundamental:
apresenta os menores valores de tempo de estudo, com mediana baixa e concentração próxima de poucas
horas semanais. #Médio: já mostra um aumento, com mediana mais alta e maior dispersão, indicando que os
estudantes dedicam mais tempo. #Superior: concentra os maiores tempos de estudo, com mediana elevada
e presença de outliers que chegam a mais de 30 horas. #Isso caracteriza um padrão crescente (monotônico):
conforme aumenta o nível de escolaridade, cresce também o tempo de estudo.

#SAUDE

#8A Histograma de pressao_sistolica e reporte média/mediana/DP.
```

Histograma

```
hist(dados$pressao_sistolica, main = "Histograma de Pressão Sistólica", xlab = "Pressão Sistólica (mmHg)",
col = "lightblue", border = "white")

#Estatísticas descritivas mean(dados$pressao_sistolica, na.rm = TRUE)

#média = 122.1863

median(dados$pressao_sistolica, na.rm = TRUE)

#mediana = 122

sd(dados$pressao_sistolica, na.rm = TRUE)

#desvio padrão = 14.05137

#8B Cruzamento diagnostico x plano_saude (% por coluna).

tab_cross <- table(dados$diagnostico, dados$plano_saude) tab_cross

prop_col <- prop.table(tab_cross, margin = 2) * 100 round(prop_col, 1)

#ambos nenhum privado SUS #DM 0.9 1.1 0.7 0.9 #HAS 12.1 12.2 12.1 12.5 #outros 5.5 6.0 6.6 6.0 #sem
81.4 80.7 80.6 80.7

#8C Interprete: qual diagnóstico é mais prevalente em cada plano?

#Em todos os planos, a maioria dos indivíduos está na categoria "sem diagnóstico" (~80%). #Entre os
diagnósticos, o mais prevalente em todos os planos é HAS (hipertensão) (~12%). #O cruzamento mostra
que a distribuição de diagnósticos é bastante semelhante entre os tipos de plano de saúde, com predominância
de ausência de diagnóstico e hipertensão como condição mais frequente entre os casos registrados.

#EXERCÍCIO 9 - Desafio

#Crie uma tabela-síntese por escolaridade com:

#n, média e mediana de idade, DP, mínimo e máximo:

library(dplyr)

dados %>% group_by(escolaridade) %>% summarise( n = n(), media_idade = mean(idade, na.rm =
TRUE), mediana_idade = median(idade, na.rm = TRUE), dp_idade = sd(idade, na.rm = TRUE),
min_idade = min(idade, na.rm = TRUE), max_idade = max(idade, na.rm = TRUE) )
```

```

#escolaridade n media_idade mediana_idade dp_idade min_idade max_idade # #1 Fundamental 3399
40.2 40 12.4 18 80 #2 Médio 4056 40.5 40 12.6 18 80 #3 Superior 2545 40.4 40 12.5 18 80

#FA/FR de plano_saude dentro de cada escolaridade:

tab <- table(dados$escolaridade, dados$plano_saude) tab #ambos nenhum privado SUS #Fundamental 105
857 415 2022 #Médio 260 719 975 2102 #Superior 269 292 1084 900

round(prop.table(tab, margin = 1) * 100, 1) #ambos nenhum privado SUS #Fundamental 3.1 25.2 12.2 59.5
#Médio 6.4 17.7 24.0 51.8 #Superior 10.6 11.5 42.6 35.4

#Produza dois gráficos: #1. Barras empilhadas de plano_saude por escolaridade (proporções).

dados %>% group_by(escolaridade, plano_saude) %>% summarise(n = n(), .groups = "drop") %>%
group_by(escolaridade) %>% mutate(prop = n / sum(n) * 100) %>% ggplot(aes(x = escolaridade, y =
prop, fill = plano_saude)) + geom_bar(stat = "identity") + labs( title = "Barras empilhadas de plano de
saúde por escolaridade (proporções)", x = "Escolaridade", y = "Proporção (%)", fill = "Plano de Saúde" )
+ theme_minimal()

#2. Boxplot de tempo_estudo_h por escolaridade

library(ggplot2)

ggplot(dados, aes(x = escolaridade, y = tempo_estudo_h)) + geom_boxplot(fill = "lightblue", color =
"darkblue") + labs( title = "Boxplot de tempo de estudo por escolaridade", x = "Escolaridade", y =
"Tempo de estudo (horas)" ) + theme_minimal()

```