

=====

MQ101 — Métodos Quantitativos para Políticas Públicas

Lista de Exercícios #04

Nome: Ana Carolina Wolff

RA: 23202510326

Turma: PPU-009 - MÉTODOS QUANTITATIVOS - TPPU00920253
(2025.3 - 4T234)

Data: 23/11/2025

Descrição: Probabilidade e inferência estatística

#EXERCICIO 1: Probabilidade como frequência de longo prazo (moeda viesada)

```
set.seed(123)
```

```
#Probabilidade de cara p_cara <- 0.3
```

```
#Tamanhos de amostra
```

```
n_vec <- c(1, 10, 100, 1000, 10000)
```

```
#Data frame para armazenar os resultados
```

```
result <- data.frame( n = n_vec, p_cara = NA_real_ )
```

```
#completar o loop para simular os lançamentos
```

```
for (i in seq_along(n_vec)) { x <- rbinom(n = 1, size = n_vec[i], prob = 0.3)
```

```
result$p_cara[i] <- x / n_vec[i] }
```

```
print(result)
```

```
#fazer um gráfico de linha da proporção de caras vs n
```

```
plot(result$n, result$p_cara, #type = "b",
```

```
pch = 19,
```

```
col = "blue",
```

```
xlab = "Tamanho da amostra (n)", ylab = "Proporção de caras", main = "Simulação: proporção de caras  
vs n")
```

```
abline(h = p_cara, lty = 2, col = "red")
```

```
#Interpretação: quanto maior a amostra, mais a frequência relativa converge para a probabilidade teórica  
de 0,3.
```

```
#EXERCÍCIO 2: Bernoulli, Binomial e probabilidades exatas (satisfação em saúde)
```

```
set.seed(123)
#Parâmetros p <- 0.65 # probabilidade verdadeira de satisfação
n <- 20 # tamanho da amostra
```

(1) Modelar satisfação como variável Bernoulli

Cada usuário: $Y \sim \text{Bernoulli}(p)$

(2) Simular uma amostra de n usuários

```
y <- rbinom(n, size = 1, prob = p)
print(y)
```

Contar o número de satisfeitos

```
num_satisfeitos <- sum(y) print(num_satisfeitos)
```

(3a) Probabilidade de observar exatamente 12 satisfeitos

```
prob_12 <- dbinom(12, size = n, prob = p)
```

(3b) Probabilidade de observar pelo menos 12 satisfeitos

```
prob_12_ou_mais <- 1 - pbinom(11, size = n, prob = p)
```

(4) Resultados

```
print(prob_12) print(prob_12_ou_mais)
```

#Interpretação: com $p = 0,65$, é comum encontrar 12 ou mais satisfeitos em 20 entrevistas, pois o valor esperado é cerca de 13.

#EXERCÍCIO 3 - Probabilidade condicional e independência (base saúde)

```
set.seed(123)
```

```
N <- 5000
```

```
dados_saude <- data.frame( sexo = sample(c("F", "M"), size = N, replace = TRUE, prob = c(0.55, 0.45)),
fumante = rbinom(N, 1, 0.22), hipertenso = rbinom(N, 1, 0.30) )
```

```
#(2) Estimar as probabilidades P_fumante <- mean(dados_saude$fumante == 1)
P_fumante_F <- -mean(dados_saude$fumante[dados_saude$sexo == "F"] == 1)
P_fumante_M <- -mean(dados_saude$fumante[dados_saude$sexo == "M"] == 1)
```

```
#(4) Gráfico de barras da proporção de fumantes por sexo
```

```
#Dica: usar dplyr + ggplot2
library(dplyr); library(ggplot2) tab_fumo <- dados_saude |> dplyr::group_by(sexo) |> dplyr::summarise(prop_fumante = mean(fumante))

ggplot(tab_fumo, aes(x = sexo, y = prop_fumante, fill=sexo)) + geom_col() + scale_fill_manual(values = c("F" = "pink", "M" = "lightblue")) + labs(x="Sexo", y="Proporção de fumantes", title="Proporção de fumantes por sexo")

#Interpretação: #A proporção de fumantes entre mulheres aparece ligeiramente maior do que entre homens.
#As diferenças, no entanto, são pequenas — ambas giram em torno de 0,22 (22%). #Isso sugere que,
neste base simulada, o hábito de fumar não varia muito entre os sexos, ou seja, fumar é aproximadamente independente de sexo.

#EXERCÍCIO 4 - Probabilidade conjunta e regra do produto (saúde)
```

(1) Probabilidades marginais e conjunta

```
P_hipertenso <- mean(dados_saudehipertenso == 1) P_fumante <- mean(dados_saudefumante == 1)
P_hip_e_fum <- mean(dados_saudehipertenso == 1 & dados_saudefumante == 1)
```

(2) Probabilidade condicional

```
P_hip_dado_fum <- mean(dados_saudehipertenso[dados_saudefumante == 1] == 1)
```

(3) Regra do Produto:

```
P_produto <- P_hip_dado_fum * P_fumante
```

(4) Interpretação

#Na base simulada, cerca de 30% dos indivíduos são hipertensos e 22% fumantes. #A probabilidade conjunta de ser fumante e hipertenso coincide com o valor obtido pela regra do produto, mostrando consistência. #Fumantes têm aproximadamente 30% de chance de serem hipertensos, um pouco acima da média geral, sugerindo associação entre tabagismo e hipertensão.

#EXERCÍCIO 5 - Bayes # Objetivo: aplicar a fórmula de Bayes em um problema de triagem de fraudes em benefícios sociais

```
set.seed(123)
```

```
P_F <- 0.02 P_T_dado_F <- 0.9 P_T_dado_Fc <- 0.05 P_Fc <- 1 - P_F
```

(1) Cálculo analítico de $P(F|Alerta)$ pela fórmula de Bayes

```
P_F_dado_T <- (P_T_dado_F * P_F) / (P_T_dado_F * P_F + P_T_dado_Fc * P_Fc)
```

(2) Simulação

```
N <- 100000 fraude <- rbinom(N, 1, P_F) alerta <- ifelse(
fraude == 1, rbinom(N, 1, P_T_dado_F), rbinom(N, 1, P_T_dado_Fc) )
```

(3) Estimar empiricamente $P(F|Alerta)$

```
P_empirico <- mean(fraude[alerta == 1] == 1)
```

(4) Comparar e interpretar em texto.

```
c( Empirico = P_empirico, Analitico = P_F_dado_T, Diferencia = P_empirico - P_F_dado_T )
#O cálculo mostra que, mesmo com sensibilidade de 90% e especificidade de 95%, a prevalência baixa (2%)
faz com que apenas cerca de 27% dos alertas sejam fraudes reais. #Isso significa que a maioria dos alertas
é de falsos positivos, e o sistema precisa de triagem adicional para evitar desperdício de tempo e recursos
#EXERCÍCIO 6 - Teorema Central do Limite (TCL) com renda
set.seed(123)
```

(1) Gerar população assimétrica de rendas

```
N <- 100000 renda_pop <- rgamma(N, shape = 2, rate = 1/2500)
```

(2) Função auxiliar para simular médias amostrais

```
simular_medias <- function(n, n_rep = 5000) { medias <- numeric(n_rep) for (i in seq_len(n_rep)) {
amostra <- sample(renda_pop, n, replace = TRUE) medias[i] <- mean(amostra) } medias }
```

(3) Simular médias para $n = 30$

```
medias_n30 <- simular_medias(30)
```

(4) Simular médias para $n = 200$

```
medias_n200 <- simular_medias(200)
```

(5) Histogramas comparativos

```
hist(medias_n30, main = "Médias amostrais de renda (n = 30)", xlab = "Média da amostra", col = "light-
blue", breaks = 30) par(mar = c(4, 4, 2, 1))
```

```
hist(medias_n200, main = "Médias amostrais de renda (n = 200)", xlab = "Média da amostra", col =
"lightgreen", breaks = 30) par(mfrow = c(1, 1))
```

#Interpretação: #A renda da população é desigual, mas quando tiramos várias amostras e calculamos a média, os resultados ficam cada vez mais parecidos com uma curva “normal”. #Com 30 pessoas já dá para ver essa tendência, e com 200 fica ainda mais claro. #quanto maior a amostra, mais as médias se organizam em torno de um padrão regular, mesmo que os dados originais sejam desiguais.

#EXERCÍCIO 7 - Intervalo de confiança para proporção (saúde)

```
set.seed(123)
```

```
N <- 5000 dados_saude <- data.frame( sexo = sample(c("F", "M"), size = N, replace = TRUE, prob = c(0.55, 0.45)), fumante = rbinom(N, 1, 0.22), hipertenso = rbinom(N, 1, 0.30) )
```

(1) Sorteio de amostra de tamanho $n = 400$

```
n <- 400 amostra_saude <- dados_saude[sample(1:nrow(dados_saude), n), ]
```

(2) Proporcao amostral e Intervalo de confiança (IC)

```
p_hat <- mean(amostra_saude$hipertenso) SE_p <- sqrt(p_hat * (1 - p_hat) / n) IC_95 <- c( inferior = p_hat - 1.96 * SE_p, superior = p_hat + 1.96 * SE_p )
```

(3) Proporcao verdadeira na população

```
p_verdadeiro <- mean(dados_saude$hipertenso)
```

(4) Resultados e interpretação

```
print(p_hat) print(p_verdadeiro) print (IC_95)
```

#Na amostra de 400 pessoas, cerca de 30% tinham hipertensão. O intervalo calculado mostra que, na população, essa proporção deve estar entre aproximadamente 26% e 34%. O valor verdadeiro da base completa (30%) está dentro desse intervalo, o que confirma que a estimativa é confiável. Em termos práticos, isso significa que podemos ter segurança de que a taxa de hipertensão na população está nesse intervalo, informação útil para planejar políticas e recursos de saúde.

#EXERCÍCIO 8 - Correlação, regressão simples e inferência (educação)

```
set.seed(123)
```

(1) Simular base de dados

```
N <- 2000
```

```
dados_educacao <- data.frame( ideb = rnorm(N, mean = 5.5, sd = 0.7),  
gasto_aluno = rnorm(N, mean = 6000, sd = 1500)  
) #IDEB:desempenho escolar
```

Introduzir correlação positiva leve

```
dados_educacaoideb <- -dados_educacaoideb + 0.0002 * (dados_educacao$gasto_aluno - 6000)
```

(2) Correlação de Pearson

```
cor_ideb_gasto <- cor(dados_educacaoideb, dados_educacao$gasto_aluno) print(cor_ideb_gasto)
```

(3) Regressão simples

```
modelo <- lm(ideb ~ gasto_aluno, data = dados_educacao) summary(modelo) #a cada 1,00 real adicional do  
gasto, espero incrementar o ideb em 0.0001938; #a cada 1.000,00 reais adicionais do gasto, espero incrementar  
o ideb em 0.1938.
```

```
confint(modelo) #o incremento pode ser entre 0.173 e 0.2146 por cada R$ 1.000,00 adicionais.
```

#Interpretação: #O coeficiente angular é positivo, indicando que maiores gastos por aluno estão associados a IDEB ligeiramente maior. #O valor é pequeno, mostrando que o efeito é leve. #O valor-p é muito baixo, sugerindo que a relação não é fruto do acaso. #O intervalo de confiança não inclui zero, reforçando a evidência de associação. #Do ponto de vista inferencial, obter um coeficiente diferente de zero significa que há indícios de que o gasto influencia o IDEB, ainda que de forma modesta. #portanto, há sinais de que investir mais por aluno está ligado a uma melhora no IDEB, mas o efeito é pequeno; ainda assim, é improvável que seja apenas coincidência. #Para políticas públicas, isso significa que o aumento de recursos deve ser acompanhado de estratégias complementares para garantir avanços significativos na qualidade da educação.

#OPCIONAL:

```
ggplot(dados_educacao, aes(x = gasto_aluno, y = ideb)) + geom_point(alpha = 0.8, color = "steelblue")  
+ geom_smooth(method = "lm", se = TRUE, color = "darkgreen") + labs(title = "Relação entre gasto por  
aluno e IDEB", x = "Gasto por aluno", y = "IDEB") + theme_minimal()
```

Exercício 9 – Margem de erro e tamanho amostral (TSE)

```
set.seed(123)
```

(1) População de municípios

```
N <- 5000 dados_tse <- data.frame( id_mun = 1:N, prop_partido = rbeta(N, shape1 = 10, shape2 = 15) )
```

(2) Parâmetros da pesquisa

```
n_amostra <- 600 n_rep <- 1000
```

(3) Simulação de pesquisas

```
p_hat_vec <- numeric(n_rep) for (r in 1:n_rep) { id_escolhido <- sample(dados_tseid_mun, 1)p_mun <- dados_tseprop_partido[id_escolhido]
votos <- rbinom(n_amostra, size = 1, prob = p_mun) p_hat_vec[r] <- mean(votos) }
```

(4) Margem de erro “de praxe” (pior caso)

```
ME <- 1.96 * sqrt(0.25 / n_amostra) print(paste("Margem de erro padrão:", round(ME*100,1), "%"))
```

(5) Histograma das proporções simuladas

```
hist(p_hat_vec, breaks = 30, col = "lightblue", border = "white", main = "Distribuição das proporções estimadas", xlab = "Proporção de votos no partido X")
```

(6) Estatísticas resumidas

```
print(paste("Média das proporções estimadas:", round(mean(p_hat_vec)100,1), "%")) print(paste("Desvio padrão das proporções estimadas:", round(sd(p_hat_vec)100,1), "%"))
```

#Interpretação: #A margem de erro é de cerca de 4% #Na prática, a variabilidade observada nas simulações pode ser menor ou maior, dependendo da proporção verdadeira de votos em cada município. #Isso mostra que a margem de erro divulgada em pesquisas eleitorais é uma aproximação, e não captura toda a incerteza ligada à escolha do município ou às diferenças locais. #explicar que se trata de uma aproximação aumenta a confiança da população nas pesquisas e no processo democrático.

#EXERCÍCIO 10: Regressão e distribuição amostral do coeficiente (TSE)

```
set.seed(123)
```

(1) População de municípios

```
N <- 5000 dados_tse <- data.frame( id_mun = 1:N, renda_media = rnorm(N, mean = 2500, sd = 600) )
```

(2) Gerar proporção de votos dependente de renda_media

```
dados_tseprop_partido <- plogis(-1 + 0.0006 * dados_tserenda_media + rnorm(N, 0, 0.3) )
```

(3) Parâmetros da pesquisa

```
n_mun_amostra <- 300 n_eleitores <- 400 n_rep <- 500
```

(4–6) Simulações

```
coef_angular <- numeric(n_rep)

for (r in 1:n_rep) { # Sortear municípios mun_sorteados <- sample(dados_tseid_mun, n_mun_amostra) base_pesq <-
  dados_tse[dados_tseid_mun %in% mun_sorteados, ]

  # Para cada município, simular votos e calcular proporção p_hat p_hat <- numeric(n_mun_amostra) for
  (i in seq_len(n_mun_amostra)) { p_true <- base_pesq$prop_partido[i] votos <- rbinom(n_eleitores, size
    = 1, prob = p_true) p_hat[i] <- mean(votos) }

  base_pesq$p_hat <- p_hat

  # Ajustar regressão simples modelo <- lm(p_hat ~ renda_media, data = base_pesq) coef_angular[r] <-
  coef(modelo)[2] }
```

(7) Histograma da distribuição dos coeficientes

```
hist(coef_angular, breaks = 30, col = "lightgreen", border = "white", main = "Distribuição amostral dos
coeficientes angulares", xlab = "Coeficiente angular (p_hat ~ renda_media)")
```

#O gráfico dos coeficientes mostra que os resultados da regressão mudam quando a gente repete a pesquisa em diferentes municípios. Ou seja, o número não é sempre igual, ele varia. #A média desses resultados fica perto do valor “real” do efeito da renda sobre o voto. Isso quer dizer que, em geral, o método está acertando. #A variação dos resultados mostra o quanto eles podem oscilar de uma pesquisa para outra. Se essa variação é pequena, temos mais confiança no número. #O intervalo de confiança é uma forma de mostrar essa variação: em vez de dar só um número, damos uma faixa de valores possíveis. #Para políticas públicas, isso significa que é preciso considerar a incerteza e trabalhar com intervalos de confiança, não só com valores pontuais.